

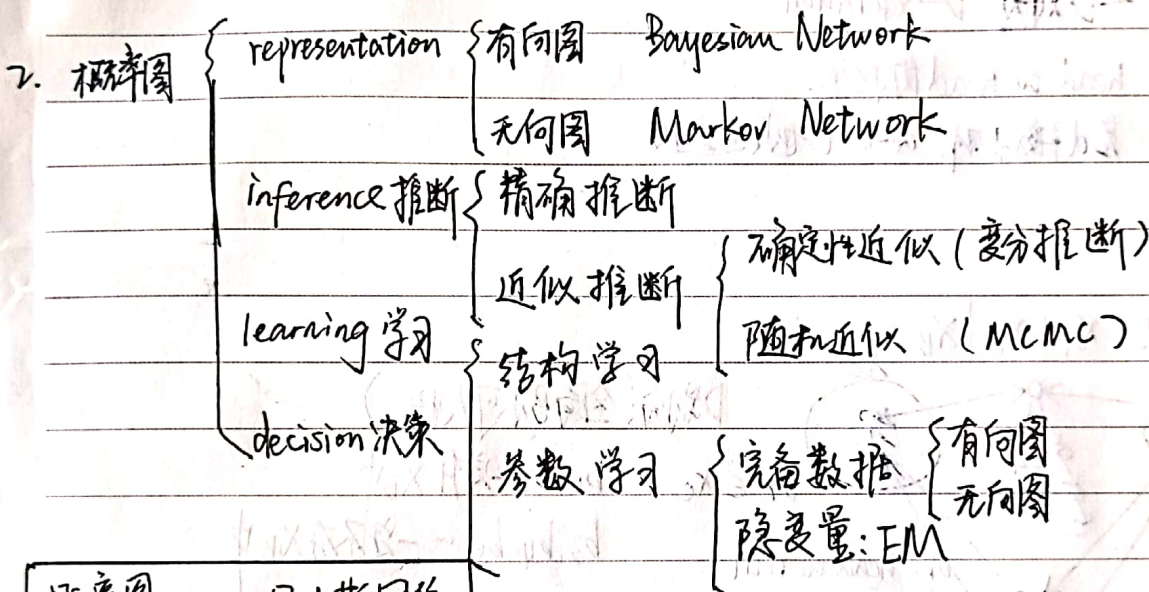
概率图1-背景介绍

1. 高维随机变量计算量大 \rightarrow 简化 $\xrightarrow{\text{相互独立}}$ $P(X_1, \dots, X_p) = \prod_{j=1}^p P(X_j)$
 Naive Bayes: $P(X|y) = \prod_{j=1}^p P(X_j|y)$

Markov Property $\rightarrow X_j \perp X_{i+1} | X_i, j < i$

HMM: 齐次 Markov 假设

条件独立性 $\rightarrow X_A \perp X_B | X_C$, X_A, X_B, X_C 是集合且不相交 (是马尔可夫性质的推广)



概率图2-贝叶斯网络


1. chain rule: $P(X_1, \dots, X_p) = P(X_1) \prod_{i=2}^p P(X_i | X_{1:i-1})$

2. 因子分解 $P(X_1, \dots, X_p) = \prod_{i=1}^p P(X_i | X_{pa(i)})$

$X_{pa(i)}$ 是 X_i 的父节点集合

3. 拓扑排序: $i < j \rightarrow [\dots, X_i, \dots, X_j, \dots]$

4. 假设已构建了一个有向图模型:



$P(a, b, c) = P(a) P(b|a) P(c|a)$

$P(a, b, c) = P(a) P(b|a) P(c|a, b)$

因子分解

链式法则

所以 $P(c|a) = P(c|a, b) \Rightarrow b, c$ 独立

证明 $P(c|a) P(b|a) = P(c|a, b) P(b|a)$

$= P(c, b|a)$


说明图与集合都能体现独立性。

$c \perp b | a \Leftrightarrow a$ 若被观测, 则路径阻塞

(无向) 路径: $b \rightarrow a \rightarrow c$ (tail to tail) tail: a 是头 b 是尾



有向图三种情况



tail to tail $b \perp c | a$

head to tail $a \perp c | b \Leftrightarrow$ 若 b 被观测, 则路径被阻塞

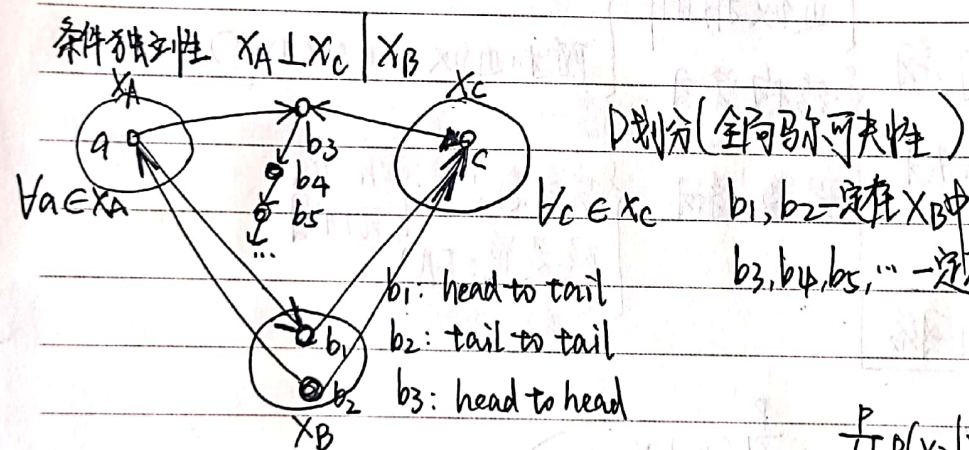
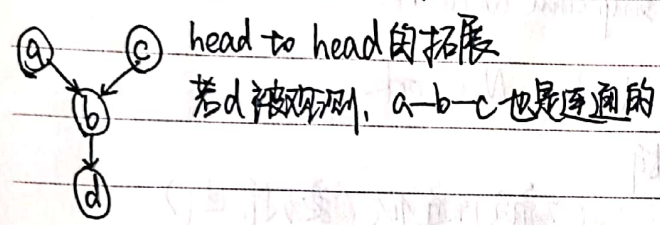
head to head 默认情况下 $a \perp b$, 路径堵塞

★ 若 c 被观测, a 和 b 不独立, 路径是通的 类比: 两口子结婚生娃 c

证明: $P(a, b, c) = P(a) P(b) P(c|a, b)$
 $= P(a) P(b|a) P(c|a, b)$

所以 $P(b) = P(b|a) \Rightarrow a \perp b$

概率图子—D划分 D-Separation




$$P(x_i | X_{-i}) = \frac{P(x_i, X_{-i})}{P(X_{-i})} = \frac{P(x_i)}{\int_{X_i} P(x_i) dx_i} = \frac{\prod_{j=1}^p P(x_j | x_{pa(j)})}{\int_{X_i} \prod_{j=1}^p P(x_j | x_{pa(j)}) dx_i}$$

表示集合 $\{x_1, \dots, x_{i-1}, x_{i+1}, \dots, x_p\}$

边缘分布转联合分布

$= f(\Delta)$, 用 Δ 表示与 x_i 相关的点的集合 (未给出证明)

i.e. x_i 与其它所有节点的关系可以简化为 x_i 与“和 x_i 连通的点集”的关系



Markov Blanket 马尔可夫毯



概率图4 — representation example

贝叶斯网络

Naive Bayes: $P(X|y) = \prod_{i=1}^p P(x_i|y=1)$

GMM: $\otimes \rightarrow \otimes$
 z is discrete
 i.e. $z=1,2,\dots,K$

带时间: Markov Chain, 随机过程的一种

连续: Gaussian Process 无限维高斯分布

Gaussian Network / Gaussian Bayesian Network

$X|Z \sim N(\mu, \Sigma)$


动态系统
 e.g. HMM
 离散状态序列马尔可夫链

e.g. LDS
 卡尔曼滤波
 线性, 连续(高斯)

e.g. Particle Filter
 非高斯, 非线性

概率图5 — Markov Network


Markov无向图. Bayesian有向图



$\forall a \in A, b \in C, \text{path}(a,b) \cap B \neq \emptyset$

$X_A \perp X_C \mid X_B$: 从A到C的路径上至少有一个节点 $\in X_B$

2. local Markov



$a \perp \{e, f\} \mid \{b, c, d\}$

邻
 a 在给定节点 $\{b, c, d\}$ 之后, 与其余节点 $\{f, e\}$ 均独立.

$a \perp \{\text{全集} - a - \text{邻居}\} \mid \text{邻居}$




3. 成对 Markov

$$X_i \perp X_j \mid X_{-ij} \quad (i \neq j)$$

总结: Markov Network 的条件独立体现在三方面: ①全局 ②局部 ③成对
Markov Network 的因式分解. 有数学证明是等价的

有向图网络的因式分解: 拓扑排序

团: 一个关于结点的集合, 结点之间相互连通; 最大团 $C_i (i=1, 2, \dots, k)$



$$P(x) = \frac{1}{Z} \prod_{i=1}^k \phi(X_{C_i})$$

$$Z = \sum_{x_1, x_2, \dots, x_p} \prod_{i=1}^k \phi(X_{C_i}) = \sum_{x_1} \sum_{x_2} \dots \sum_{x_p} \prod_{i=1}^k \phi(X_{C_i})$$

归一化常数

ϕ : 势函数, 必须为正

Hammersley-Clifford 定理: MRF 与 马尔可夫分布等价

$\phi(X_{C_i}) = \exp(-E(X_{C_i}))$, 取指数势函数的 $P(x)$: Gibbs Distribution

$$P(x) = \frac{1}{Z} \prod_{i=1}^k \phi(X_{C_i})$$

$$= \frac{1}{Z} \prod_{i=1}^k \exp(-E(X_{C_i}))$$

$$= \frac{1}{Z} \exp\left(-\sum_{i=1}^k E(X_{C_i})\right)$$

指数族分布

指数族分布

$$P(x) = h(x) \cdot \exp\{\eta^T \phi(x) - A(\eta)\}$$

$$= \frac{1}{Z(\eta)} h(x) \cdot \exp\{\eta^T \phi(x)\}$$

最大熵原理 \Rightarrow 指数族分布

Markov Random Field \Leftrightarrow Gibbs Distribution \Leftarrow 最大熵原理




3. 成对 Markov

$$X_i \perp X_j \mid X_{-ij} \quad (i \neq j)$$

总结: Markov Network 的条件独立体现在三方面: ①全局 ②局部 ③成对
Markov Network 的因子分解. 有数学证明是等价的

有向图网络的因子分解: 拓扑排序

团: 一个关于结点的集合, 结点之间相互连通; 最大团: $C_i (i=1, 2, \dots, k)$



$$P(x) = \frac{1}{Z} \prod_{i=1}^k \phi(x_{C_i})$$

$$Z = \sum_{\text{归一化常数}} \prod_{i=1}^k \phi(x_{C_i}) = \sum_{x_1} \sum_{x_2} \dots \sum_{x_p} \prod_{i=1}^k \phi(x_{C_i})$$

ϕ : 势函数, 必须为正

Hammersley-Clifford 定理: MRF 与吉布斯分布等价

$\phi(x_{C_i}) = \exp(-E(x_{C_i}))$. 取指数势函数 $P(x)$: Gibbs Distribution

$$P(x) = \frac{1}{Z} \prod_{i=1}^k \phi(x_{C_i})$$

$$= \frac{1}{Z} \prod_{i=1}^k \exp(-E(x_{C_i}))$$

$$= \frac{1}{Z} \exp\left(-\sum_{i=1}^k E(x_{C_i})\right)$$

指数族分布

指数族分布

$$p(x) = h(x) \cdot \exp\{\eta^T \phi(x) - A(\eta)\}$$

$$= \frac{1}{Z(\eta)} h(x) \cdot \exp\{\eta^T \phi(x)\}$$

最大熵原理 \Rightarrow 指数族分布

Markov Random Field \Leftrightarrow Gibbs Distribution \Leftarrow 最大熵原理

